

Wasserstein Auto-Encoders

2018.10.04

Ridge-i 論文よみかい

Masanari Kimura

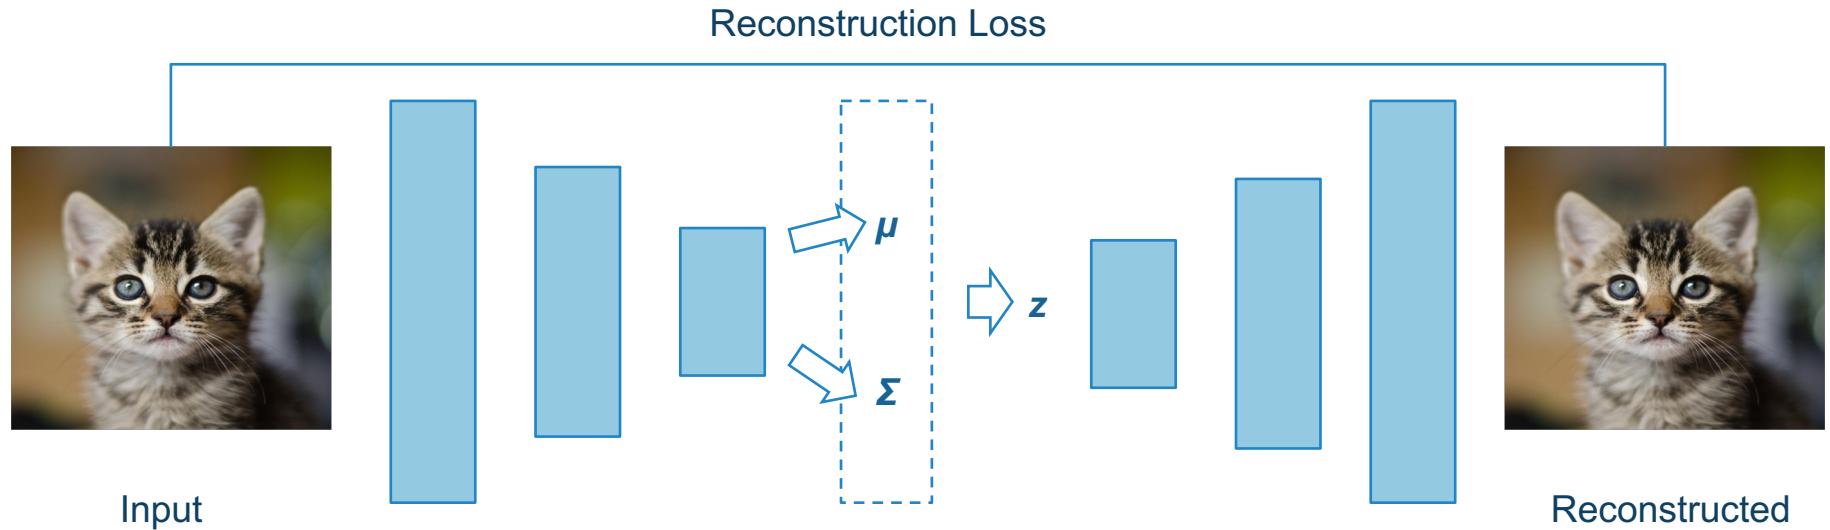
mkimura@ridge-i.com



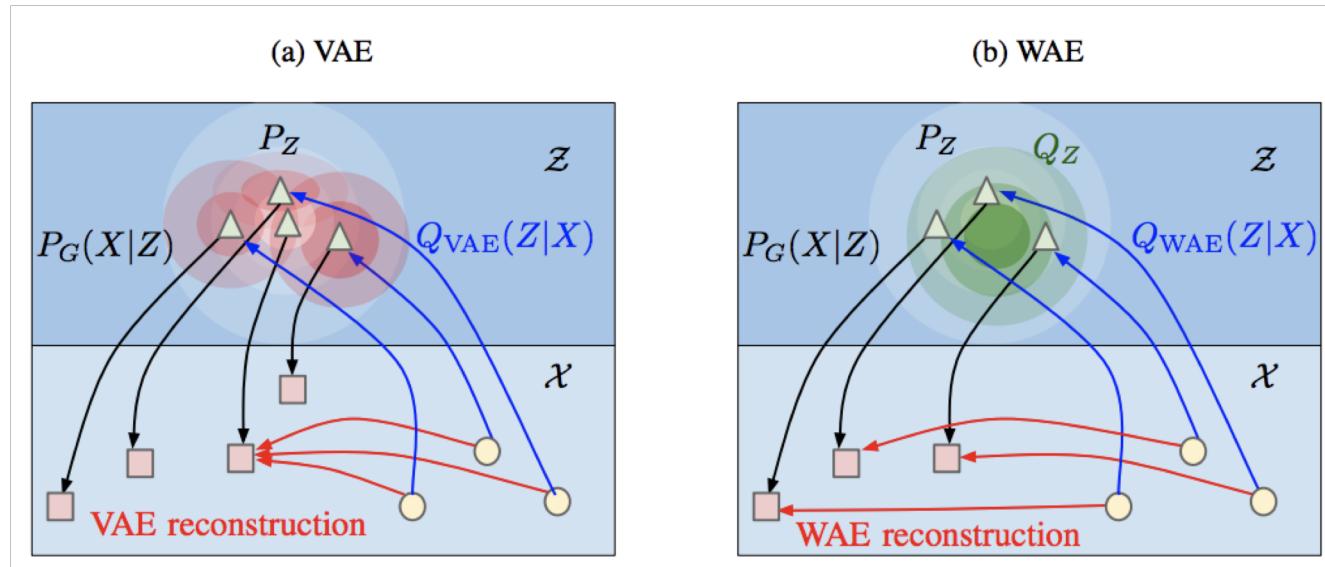
- ICLR2018採択論文 [1]
- 生成モデルの学習手法の提案.

- Optimal transport costを最小化するように学習するWAEの提案
- GANベースとMMDベースの二つのregularizersを提案
- VAEの安定性と良好な潜在空間を保ったまま、より綺麗な画像の生成が可能

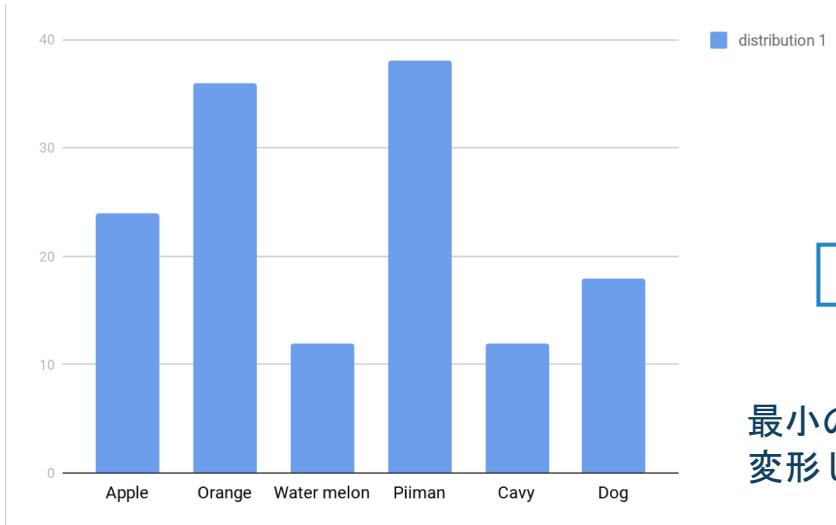
- 潜在変数 z が $P_z = N(0, I_d)$ からサンプリングされると仮定して学習



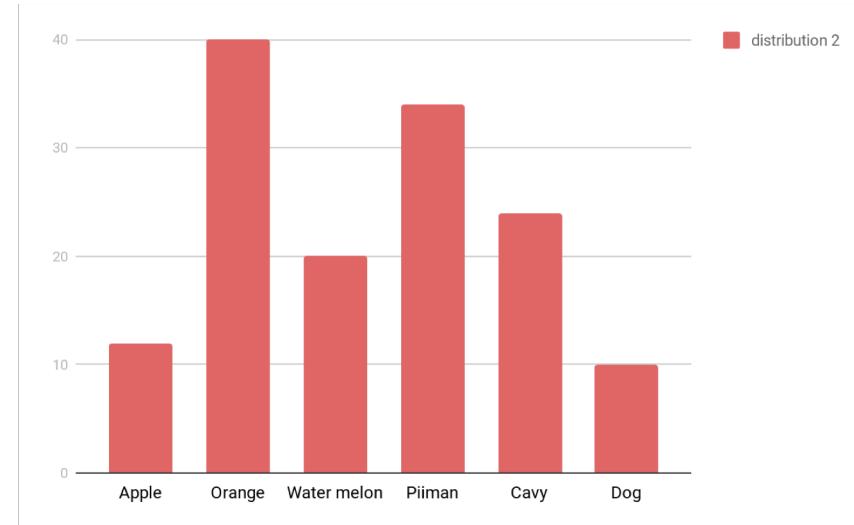
- VAE: 全てのデータ点が潜在空間上で P_z に従うように学習
 - 異なるデータ点のマージンが交差するため、デコード時に問題が起きる
- WAE: 異なるデータ点は潜在空間上で互いに離れるように学習



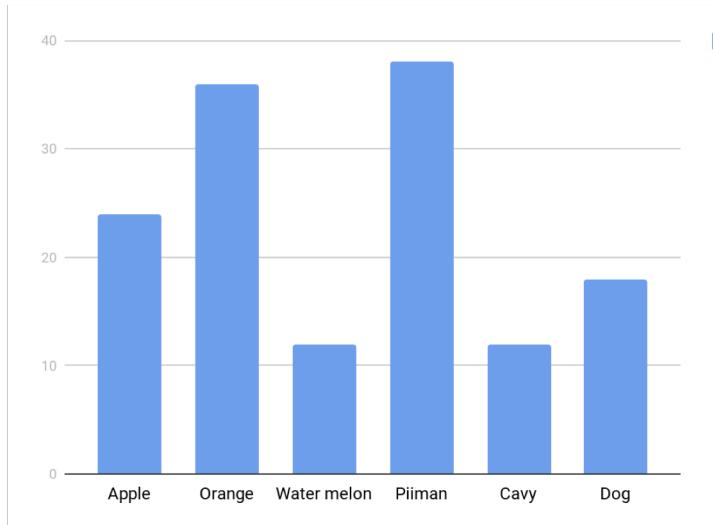
- 多くの確率分布間のダイバージェンスは、**最適輸送問題**によって導出される [2]



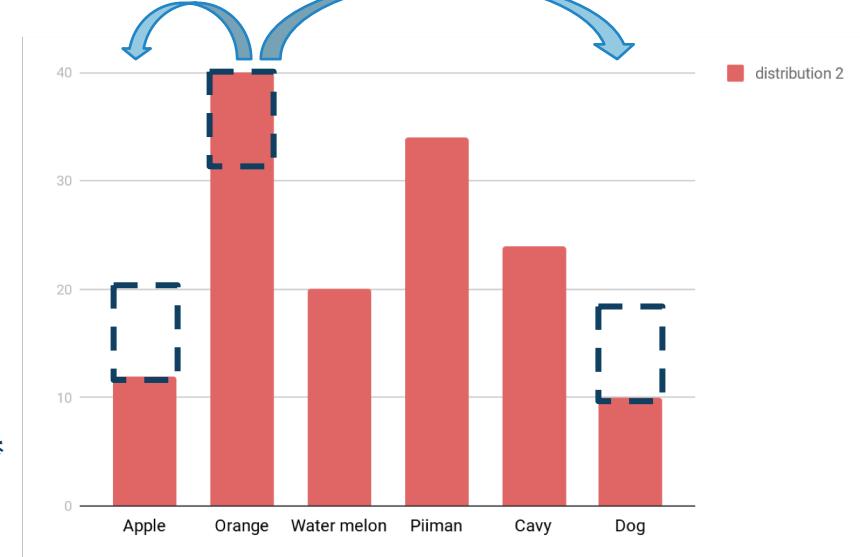
最小の労力で
変形したい



- 多くの確率分布間のダイバージェンスは、最適輸送問題によって導出される [2]



最小の労力で
変形したい



Orangeと間違えたものは、
Dogに運ぶよりAppleに運ぶほうが楽

- 以下の問題を考える
 - $c(X, Y)$ は任意のコスト関数
 - $P(X \sim P_X, Y \sim P_G)$ は real と generated の結合分布から得られる (X, Y) の集合

$$W_c(P_X, P_G) := \inf_{\Gamma \in \mathcal{P}(X \sim P_X, Y \sim P_G)} \mathbb{E}_{(X, Y) \sim \Gamma} [c(X, Y)],$$

- 特に $c(X, Y) = d^p(X, Y)$ の時, $W_c(X, Y)$ の p 乗根 $W_p(X, Y)$ を p -Wasserstein distance という

$$W_c(P_X, P_G) := \inf_{\Gamma \in \mathcal{P}(X \sim P_X, Y \sim P_G)} \mathbb{E}_{(X, Y) \sim \Gamma} [c(X, Y)],$$

- ここで, $c(x, y) = d(x, y)$, つまり $p=1$ の時, 次の双対問題が成り立つ:
 - Kantorovich-Rubinstein duality

$$W_1(P_X, P_G) = \sup_{\substack{f \in \mathcal{F}_L}} \mathbb{E}_{X \sim P_X} [f(X)] - \mathbb{E}_{Y \sim P_G} [f(Y)],$$

1-Lipschitz関数

- 潜在表現 z がある分布からサンプリングされているとする
- z に何らかの変形を施すことで画像空間にマッピングする時、生成モデルの確率密度は

$$p_G(x) := \int_{\mathcal{Z}} p_G(x|z)p_z(z)dz, \quad \forall x \in \mathcal{X},$$

- Auto-Encodersの枠組みでは、 z はエンコーダの出力

- 以下の結合分布について考える

$$\gamma(x, y) = \int p(y|z)q(z|x)p_X(x)dz$$

- x について積分し、周辺化する

$$\int \gamma(x, y)dx = p_G(y) = \int \int p(y|z)q(z|x)p_X(x)dxdz$$

- 上式の、 x に絡む項のみに注目すると、

$$\int q(z|x)p_X(x)dx = p_Z(z)$$

- $x \sim p_X(x), y \sim p_G(y)$ 間の最適輸送問題を考える。前スライドの期待値の部分を積分に変形して、

$$W(P_X, P_Y) = \inf_{\gamma} \int c(x, y)\gamma(x, y)dxdy$$

$$W(P_X, P_Y) = \inf_{\gamma} \int c(x, y)p(y|z)q(z|x)p_X(x)dzdxdy$$

- ここで、デコーダが決定的であると仮定すると、 $\overline{p(y|z)} = \delta(y - G(z))$ 、 $\int \delta(x - a)f(x)dx = f(a)$ から

$$W(P_X, P_Z) = \int c(x, G(z))q(z|x)p_X(x)dxdz$$

$$W(P_X, P_Z) = \inf_{q(z|x)} E_X E_{q(z|x)} c(x, G(z))$$

(制約として $\int q(z|x)p_X(x)dx = p_Z(z)$)

- GAN-based
or
MMD-based

ALGORITHM 1 Wasserstein Auto-Encoder with GAN-based penalty (WAE-GAN).

Require: Regularization coefficient $\lambda > 0$.
 Initialize the parameters of the encoder Q_ϕ , decoder G_θ , and latent discriminator D_γ .
while (ϕ, θ) not converged **do**
 Sample $\{x_1, \dots, x_n\}$ from the training set
 Sample $\{z_1, \dots, z_n\}$ from the prior P_Z
 Sample \tilde{z}_i from $Q_\phi(Z|x_i)$ for $i = 1, \dots, n$
 Update D_γ by ascending:

$$\frac{\lambda}{n} \sum_{i=1}^n \log D_\gamma(z_i) + \log(1 - D_\gamma(\tilde{z}_i))$$

Update Q_ϕ and G_θ by descending:

$$\frac{1}{n} \sum_{i=1}^n c(x_i, G_\theta(\tilde{z}_i)) - \lambda \cdot \log D_\gamma(\tilde{z}_i)$$

end while

ALGORITHM 2 Wasserstein Auto-Encoder with MMD-based penalty (WAE-MMD).

Require: Regularization coefficient $\lambda > 0$, characteristic positive-definite kernel k .

Initialize the parameters of the encoder Q_ϕ , decoder G_θ , and latent discriminator D_γ .

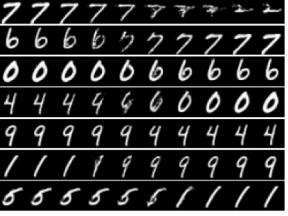
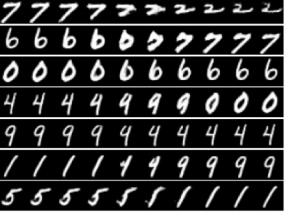
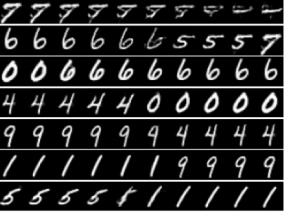
while (ϕ, θ) not converged **do**
 Sample $\{x_1, \dots, x_n\}$ from the training set
 Sample $\{z_1, \dots, z_n\}$ from the prior P_Z
 Sample \tilde{z}_i from $Q_\phi(Z|x_i)$ for $i = 1, \dots, n$
 Update Q_ϕ and G_θ by descending:

$$\begin{aligned} & \frac{1}{n} \sum_{i=1}^n c(x_i, G_\theta(\tilde{z}_i)) + \frac{\lambda}{n(n-1)} \sum_{\ell \neq j} k(z_\ell, z_j) \\ & + \frac{\lambda}{n(n-1)} \sum_{\ell \neq j} k(\tilde{z}_\ell, \tilde{z}_j) - \frac{2\lambda}{n^2} \sum_{\ell, j} k(z_\ell, \tilde{z}_j) \end{aligned}$$

end while

Experimental Results

- MNISTデータセット

	VAE	WAE-MMD	WAE-GAN
Test interpolations			
Test reconstructions			
Random samples			

Experimental Results

- CelebAデータセット



- Optimal transport costを用いた新しい生成モデルの学習手法を提案
- 既存のVAEと比べて、より綺麗な画像の生成が可能になった

- [1] Ilya Tolstikhin, Olivier Bousquet, Sylvain Gelly, Bernhard Schoelkopf. "Wasserstein Auto-Encoders", International Conference on Learning Representations (ICLR). 2018.
- [2] C. Villani. Topics in Optimal Transportation. AMS Graduate Studies in Mathematics, 2003.